

Recomendación en videojuegos basada en emociones

Benito Alonso Oliva Testa ♠ Justo Matías Solís Zlatar ◇ Daniel Ignacio Vera Ortiz ♣

Pontificia Universidad Católica de Chile

♠benito.oliva@uc.cl ◇jsolisz@estudiante.uc.cl

♣di.vera@uc.cl

Introducción

Actualmente, los sistemas de recomendación de videojuegos en plataformas como Steam o Epic Games se basan principalmente en información implícita y explícita de los usuarios, sin considerar la motivación emocional que desean experimentar. Este proyecto propone un modelo de ensamble que integra información implícita, explícita y la experiencia emocional que el usuario busca, para generar recomendaciones más personalizadas.

Objetivo

El objetivo del proyecto es desarrollar un modelo de ensamble entre un recomendador tradicional (como *DeepFM*), que considera el comportamiento del usuario, y un componente basado en NLP que interpreta un prompt donde el usuario expresa la emoción que desea experimentar. El sistema busca mapear esa intención emocional con juegos compatibles, evaluando su desempeño según diferentes métricas vistas en el curso.

Dataset

Para el desarrollo de este proyecto, se utilizaron 3 datasets de Steam y un archivo con metadata. Aquí, se consideraron solamente los videojuegos con más de 100 *reviews*. Estos archivos son:

1. **games.csv** (Archivo con 35.032 registros con la información de los juegos).
2. **recommendations.csv** (Archivo con 1.539.390 registros, con las recomendaciones de los usuarios).
3. **users.csv** (Archivo con 8.364 registros, con información de los usuarios).
4. **game-metadata.json** (Archivo con 50.872 registros, que entrega las descripciones y tags de los juegos).

Modelos usados

- **Baseline:** Los modelos que conformarán el *baseline* son *Random*, *Most Popular* e *Item-based Collaborative Filtering* (IBCF). El primero selecciona ítems al azar, el segundo realiza recomendaciones en base a los más populares, mientras que IBCF recomienda según similitudes entre ítems, en base a las preferencias de los usuarios.
- **DeepFM:** Modelo de aprendizaje automático que combina *Factorization Machines* con *Deep Neural Networks*, permitiendo un mejor aprendizaje de relaciones simples y capturar relaciones complejas y/o no evidentes.

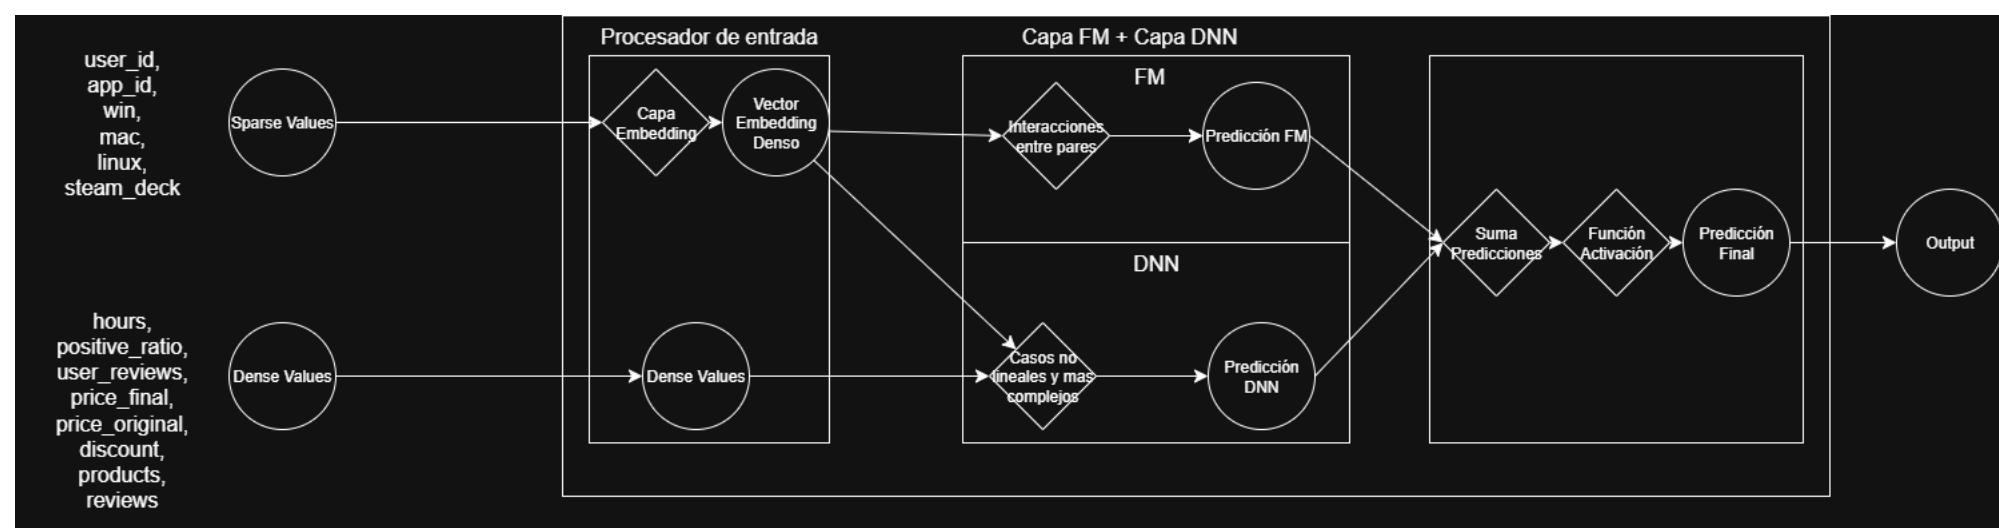


Figure 1: DeepFM

- **NLP (Emotion-based):** Utiliza el modelo preentrenado **BERT base uncased**, fine-tuneado por **bhadresh-savani** en el dataset **GoEmotions**, para recibir texto y entregar un diccionario con puntuaciones entre 0 y 1 para las emociones: *love*, *fear*, *joy*, *sadness*, *surprise* y *anger*. En este proyecto, se concatenaron el título, descripción y etiquetas de cada juego como input del modelo, y se almacenó la puntuación de cada emoción en columnas del DataFrame. El score para cada usuario se obtiene a través de similitud de coseno entre vector de emociones del *prompt* con los de los juegos, como se muestra a continuación:

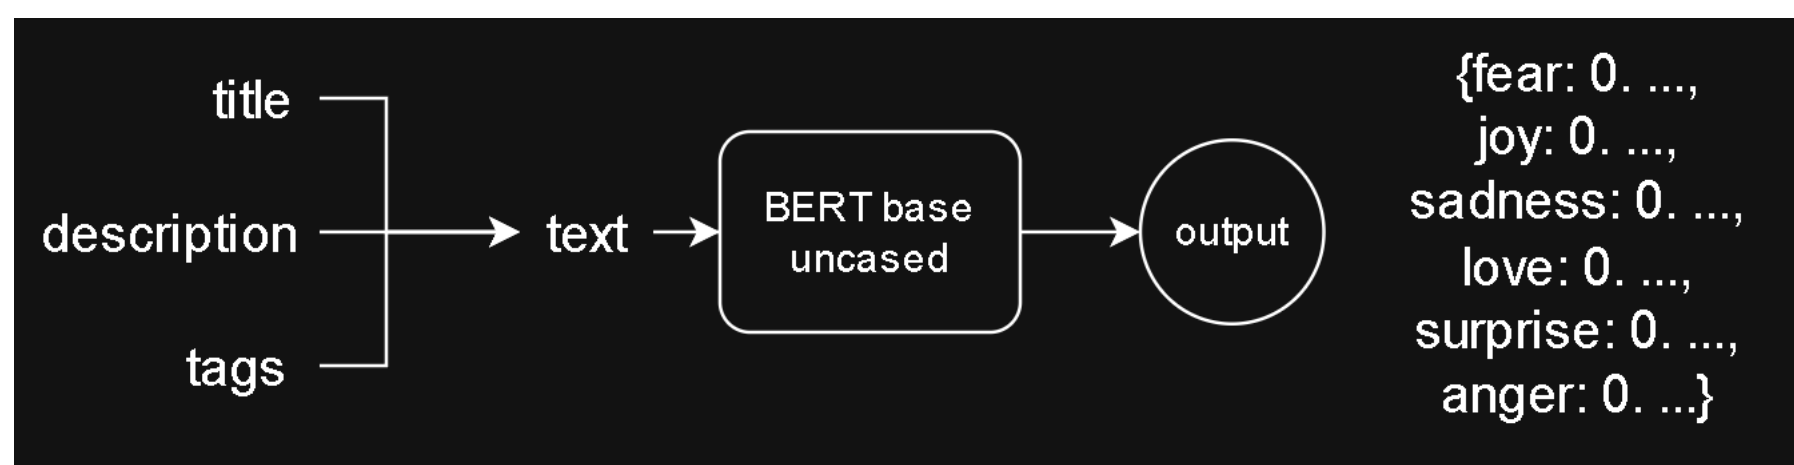


Figure 2: NLP basado en emociones

- **Ensamble (*DeepFM* + NLP):** Este modelo combina los *scores* de recomendación entregados por los modelos *DeepFM* y NLP, para que el modelo considere las emociones del usuario al realizar la recomendación. Matemáticamente, se puede expresar de la siguiente forma:

$$S_{ensemble}(u, i) = \alpha * S_{DFM}(u, i) + (1 - \alpha) * S_{NLP}(i) \quad (1)$$

Experimentos y Resultados

Para trabajar en los modelos de recomendación, se dividió la información en datasets de entrenamiento y validación, de los que se obtuvieron diversas estadísticas, las que se pueden ver en la siguiente tabla:

Estadísticas	Entrenamiento	Validación
Número de usuarios	8.364	8.364
Número de juegos	34.388	26.382
<i>Reviews</i> totales	1.228.168	310.423
Promedio de <i>reviews</i> por usuario	146,84	37,21
Promedio de <i>reviews</i> por juego	35,71	11,52
Tasa de <i>reviews</i> positivas	77,97%	78,06%
Densidad (%)	0,43%	0,14%

Table 1: Estadísticas de entrenamiento y validación

Los resultados obtenidos al procesar los modelos se pueden ver en la siguiente tabla:

Indicadores	<i>Random</i>	<i>Most popular</i>	Item kNN	<i>DeepFM</i>	Ensamble
Recall@10	0,0003	0,0200	0,0042	0,3407	0,3391
MAP@10	0,0003	0,0183	0,0007	0,7046	0,7020
nDCG@10	0,0041	0,1866	0,0015	0,9090	0,9059
NoveltyG@10	16,9452	9,4787	...	12.7812	12,8390
Diversity@10	0,9905	0,6597	...	0.9515	0,9425

Table 2: Resultados

Discusión

- De los resultados obtenidos en la tabla anterior, es posible inferir que el añadir las emociones en la recomendación no afecta demasiado las métricas de ranking. Por lo tanto, se podría obtener una mejor recomendación personalizada según las emociones que busque experimentar el usuario.
- A su vez, es necesario destacar las limitaciones del trabajo, las cuales son utilizar un modelo preentrenado, debido a que funcionaría mejor fine-tunearlo a nuestro contexto en particular, y el conjunto de datos, ya que no hay imágenes de los juegos y comentario de la recomendación del usuario.
- Por último, se sugiere que futuros trabajos exploren otros conjuntos de datos, diferentes dominios diferentes al de videojuegos y enfoques similares al propuesto, donde un modelo alimente directamente a otro como parte de un sistema de recomendación integrado.

Bibliografía

1. Y. Gajula. *Sentiment-Aware recommendation systems in E-Commerce: A review from a Natural Language Processing Perspective*, 2025.
2. L. Yuan, M. Ding, F. Meng y Y. Tian. *Sentiment Analysis and Rating Video Game Dimensions via NLP*.
3. M. Sanadi, S. More, V. Shinde y H. Raghuvanshi. *Game Recommendation System Based on User Mood*, 2024.
4. J. Leung, I. Griva y W. Kennedy. *Text-Based Emotion Aware Recommender*, 2020.