



Métodos de agregación grupal

Mathías Lambert^{1,2} y Jaime Perez¹

¹ Department of Electrical Engineering, Pontificia Universidad Católica de Chile, Santiago, Chile; ² Biomedical Imaging Center, Pontificia Universidad Católica de Chile, Santiago, Chile

Introducción

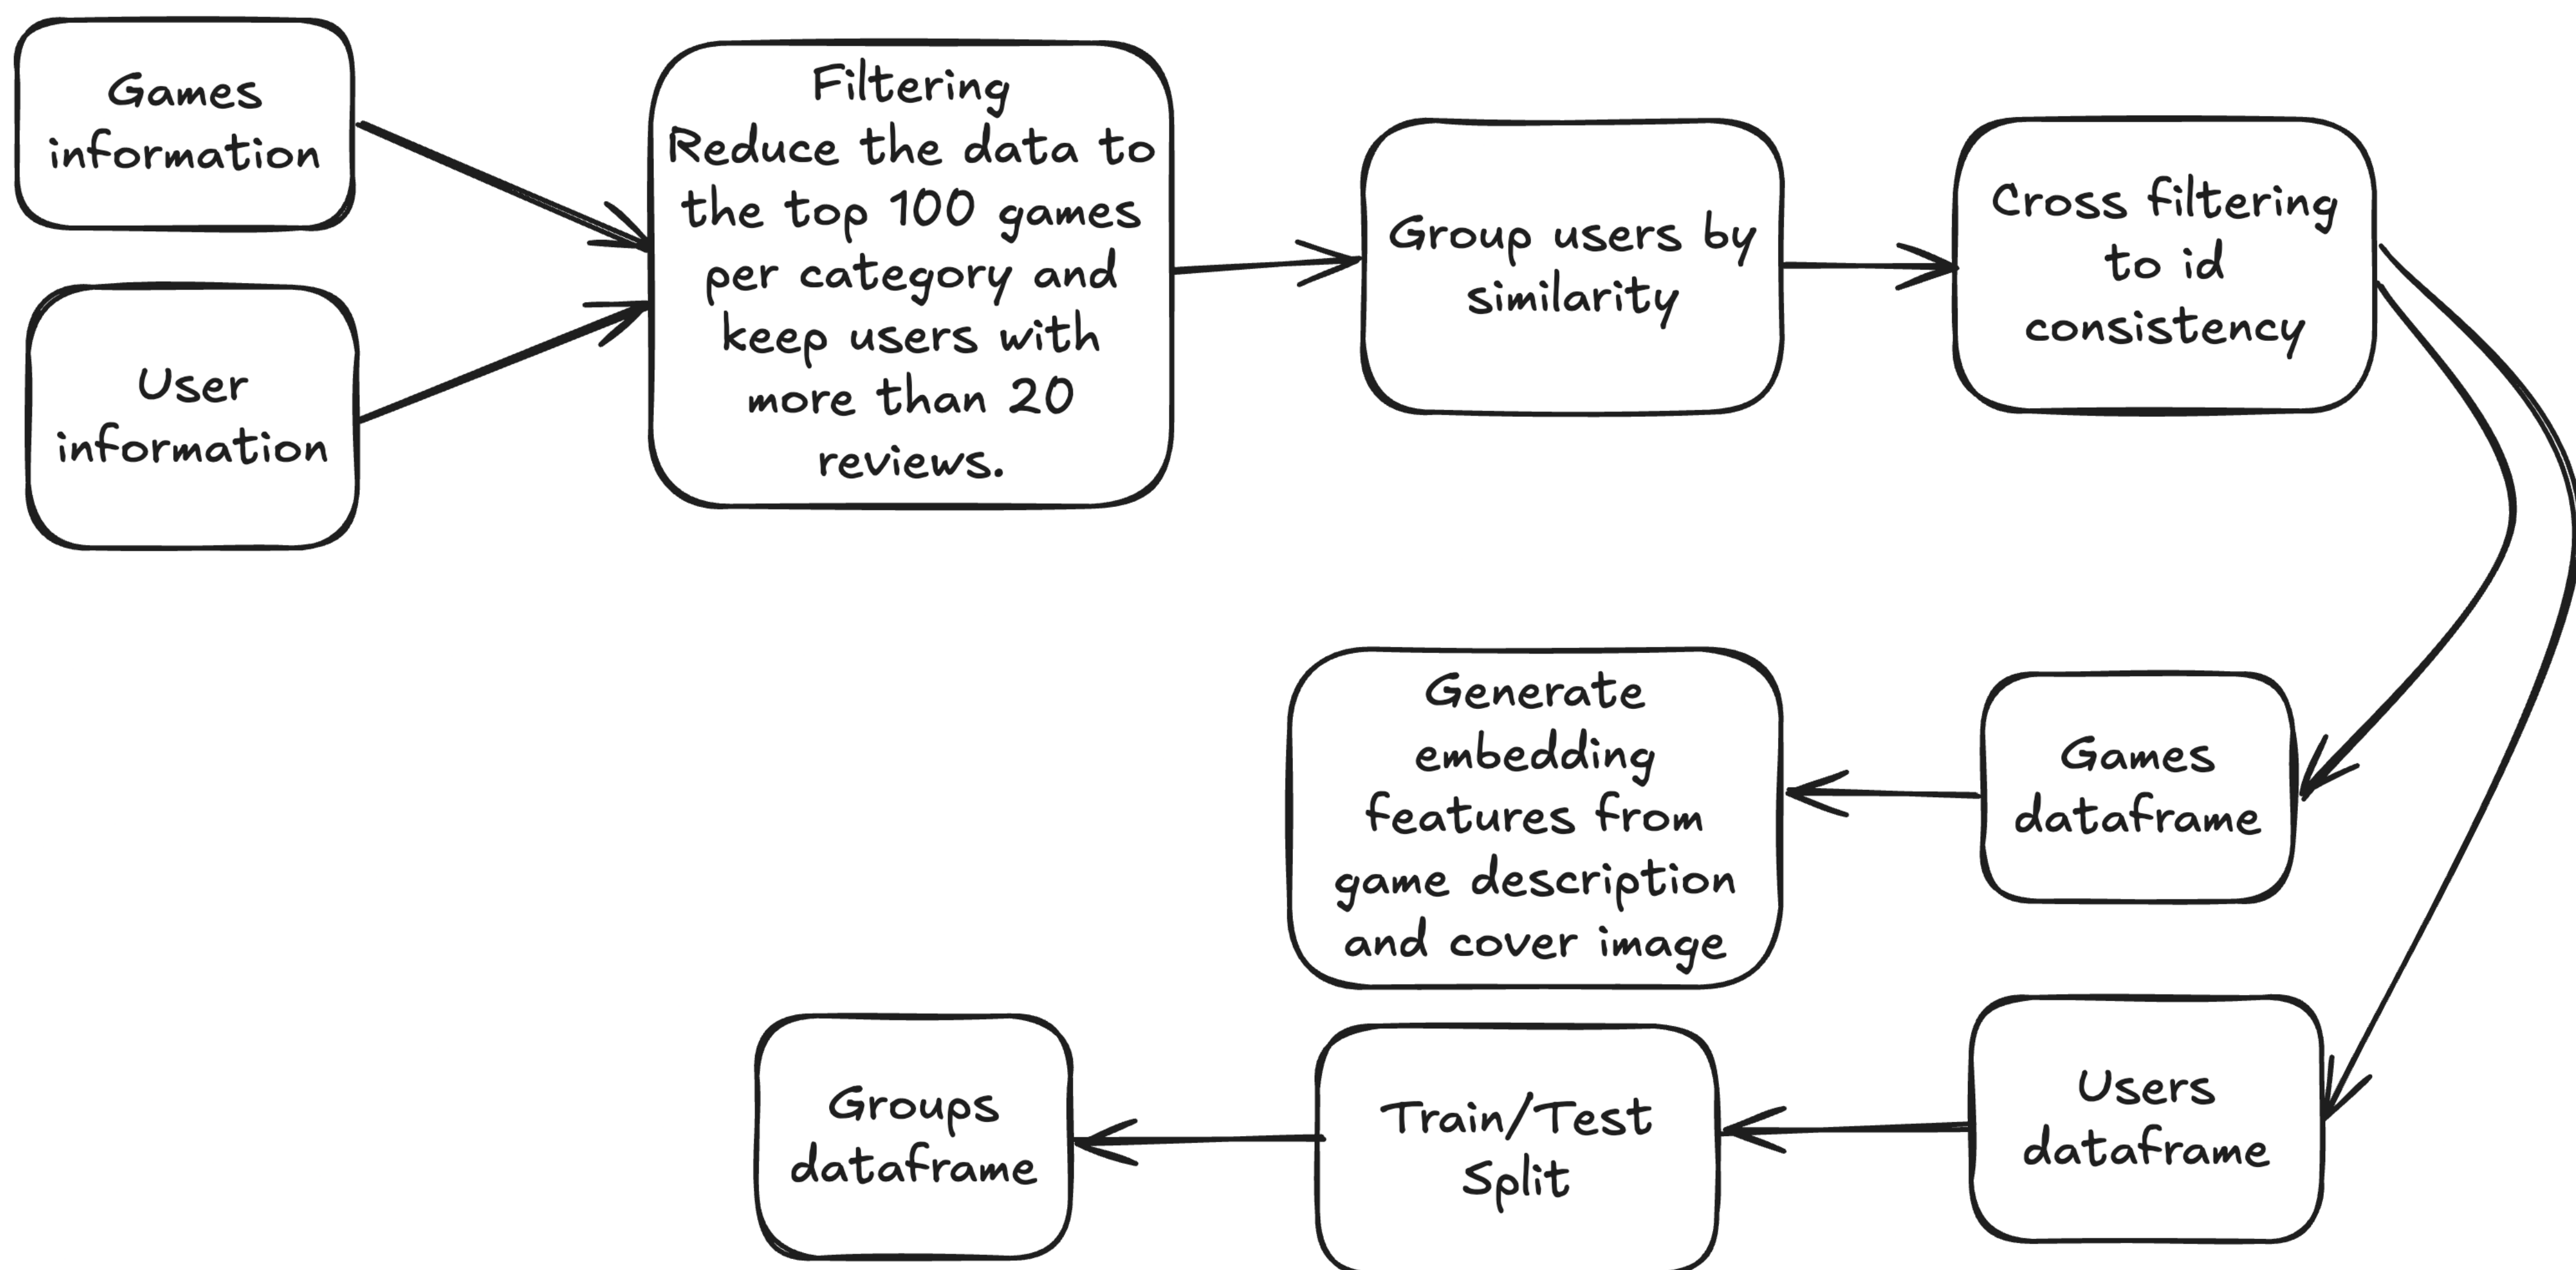
- La recomendación para grupos es un desafío complejo. A diferencia de un solo usuario, un grupo tiene preferencias conflictivas que deben ser reconciliadas.
- La forma en que se combinan (agregan) las preferencias individuales para formar un perfil de grupo es un paso crítico.
- Este trabajo analiza cuantitativamente cómo diferentes estrategias de agregación de preferencias impactan el rendimiento de modelos de recomendación de juegos de mesa.**

Métodos de agregación

Estrategia	Cómo funciona
Average	Promedia las calificaciones individuales.
Multiplicative	Multiplica las calificaciones individuales.
Borda count	Cuenta puntos de las clasificaciones de los ítems en las listas de preferencias individuales, con el ítem inferior obteniendo 0 puntos, el siguiente 1 punto, etc.
Copeland score	Cuenta cuántas veces un ítem vence a otros ítems (usando el voto mayoritario) menos cuántas veces pierde.
Approval voting	Cuenta las calificaciones individuales con calificaciones para el ítem por encima del umbral de aprobación (ej. 6).
Least Misery	Toma el mínimo de las calificaciones individuales.
Most pleasure	Toma el máximo de las calificaciones individuales.
Average without Misery	Promedia las calificaciones individuales, después de excluir los ítems con calificaciones individuales por debajo de un umbral (digamos 4).
Fairness	Los ítems se clasifican a medida que los individuos los eligen por turnos.
Most respected person (or Dictatorship)	Utiliza la calificación del individuo más respetado.

Metodología

- Dataset:** Utilizamos un conjunto de datos proveniente de BoardGameGeek.



- Modelos de Recomendación:**
 - Baselines:** Random, Most popular, SVD++.
 - Modelo Propuesto:**
 - Nuestro modelo propuesto utiliza XGBoost para predecir el rating de un juego para un usuario específico.
 - La representación de cada usuario es un vector único, creado a partir de la suma ponderada y normalizada de los embeddings de los juegos que ya ha calificado.
 - Para mejorar la predicción, se añade como característica clave la distancia coseno entre el vector del usuario y el embedding del juego cuyo rating se quiere estimar.
- Experimentos:**
 - Recomendación individual. Métricas: MAE y RMSE.
 - Evaluación de las listas de recomendación agregadas. Métricas evaluadas como el promedio entre los usuarios del grupo: Precisión@10y NDCG@10.

Discusión y Conclusiones

- El modelo Most Popular superó a los modelos complejos (XGB, SVD++) en la recomendación grupal (NDCG).
- La precisión en predecir ratings individuales (bajo RMSE) no garantiza una buena recomendación para grupos, donde el consenso es clave.
- La combinación más efectiva fue el modelo Most Popular junto a la estrategia de agregación average_without_misery.

	Random Most Popular SVD++ XGB			
MAE	2,87	2,18	0,91	0,93
RMSE	3,51	2,45	1,21	1,21

	Precisión@10				NDCG@10			
	preds_popular	preds_random	preds_svdpp	preds_xgb	preds_popular	preds_random	preds_svdpp	preds_xgb
approval_voting	0.300 ± 0.000	0.050 ± 0.000	0.100 ± 0.000	0.050 ± 0.000	0.652 ± 0.000	0.231 ± 0.000	0.500 ± 0.000	0.151 ± 0.000
average	0.300 ± 0.000	0.050 ± 0.000	0.100 ± 0.000	0.050 ± 0.000	0.652 ± 0.000	0.424 ± 0.000	0.500 ± 0.000	0.250 ± 0.000
average_without_misery	0.150 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.720 ± 0.000	0.500 ± 0.000	0.000 ± 0.000	0.000 ± 0.000
borda_count	0.300 ± 0.000	0.050 ± 0.000	0.100 ± 0.000	0.050 ± 0.000	0.652 ± 0.000	0.424 ± 0.000	0.466 ± 0.000	0.193 ± 0.000
copeland_score	0.300 ± 0.000	0.000 ± 0.000	0.100 ± 0.000	0.000 ± 0.000	0.652 ± 0.000	0.193 ± 0.000	0.500 ± 0.000	0.000 ± 0.000
fairness	0.300 ± 0.000	0.050 ± 0.000	0.100 ± 0.000	0.050 ± 0.000	0.652 ± 0.000	0.294 ± 0.000	0.466 ± 0.000	0.178 ± 0.000
least_misery	0.300 ± 0.000	0.150 ± 0.000	0.100 ± 0.000	0.050 ± 0.000	0.652 ± 0.000	0.637 ± 0.000	0.500 ± 0.000	0.151 ± 0.000
most_pleasure	0.300 ± 0.000	0.050 ± 0.000	0.100 ± 0.000	0.050 ± 0.000	0.652 ± 0.000	0.294 ± 0.000	0.500 ± 0.000	0.250 ± 0.000
most_respected_person	0.300 ± 0.000	0.000 ± 0.000	0.100 ± 0.000	0.000 ± 0.000	0.652 ± 0.000	0.193 ± 0.000	0.500 ± 0.000	0.000 ± 0.000
multiplicative	0.300 ± 0.000	0.050 ± 0.000	0.100 ± 0.000	0.050 ± 0.000	0.652 ± 0.000	0.424 ± 0.000	0.500 ± 0.000	0.250 ± 0.000