
Recomendador híbrido con métodos lineales optimizados y enfoques memory-based

Felipe Abarca¹ Alfredo Enrione¹ Nicolás Estévez¹ <https://github.com/aenrione/Sapling-DAN>¹

Abstract

Los modelos lineales y los enfoques *memory-based* han demostrado ser altamente efectivos en sistemas de recomendación, aunque cada uno presenta limitaciones estructurales particulares. En este trabajo proponemos una arquitectura híbrida que integra lo mejor de ambos mundos, combinando la eficiencia y capacidad de generalización de modelos como DAN (Data-Adaptive Normalization) con la capacidad interpretativa y modelado de disimilitudes de Sapling Similarity. Introducimos tres variantes de integración: *Pipeline*, *Combine* y *Regularization*, que permiten fusionar predicciones y estructuras relacionales en distintos niveles. Evaluamos nuestro enfoque en cuatro datasets reales (Amazon Books, Amazon Products, Yelp Reviews y MovieLens), mostrando que la combinación propuesta mejora métricas clave como precisión, diversidad y nDCG, particularmente destacando el método de Regularización. Además, presentamos un análisis de sensibilidad que evidencia la capacidad del modelo para ajustar el balance entre precisión y novedad mediante hiperparámetros de control. Nuestros resultados sugieren que las estrategias híbridas diseñadas permiten superar las debilidades individuales de los modelos base, estableciendo una vía efectiva para recomendaciones más robustas y diversas.

1.Introducción

Los sistemas de recomendación juegan un rol fundamental en múltiples plataformas digitales, facilitando la personalización de contenidos y mejorando la experiencia del usuario. En este trabajo comenzamos explorando dos familias de métodos ampliamente utilizados en este dominio: los modelos

^{*}Contribución equitativa ¹Pontificia Universidad Católica de Chile, Santiago, Chile. Correspondence to: Felipe Abarca <felipe.abarca@uc.cl>, Alfredo Enrione <aenrione@uc.cl>, Nicolás Estévez <nestevez@uc.cl>.

lineales y los métodos *memory-based*.

Los enfoques lineales destacan por su eficiencia computacional y su capacidad para aprender representaciones interpretables a partir de interacciones usuario-ítem. En particular, modelos como EASE, LAE y RLAE, han mostrado un rendimiento competitivo frente a modelos no lineales más complejos. Sin embargo, estos modelos suelen estar afectados por sesgos estructurales, como el sesgo de popularidad y el sesgo de vecinos cercanos, lo que limita la diversidad y la calidad de las recomendaciones.

Por otro lado, los métodos *memory-based*, presentan una alta interpretabilidad y permiten modelar explícitamente tanto similitudes como disimilitudes entre usuarios o ítems. A pesar de su simplicidad, estos métodos han demostrado resultados notables, especialmente en datasets con estructuras más dispersas o menos homogéneas. No obstante, suelen tener un poder de generalización limitado, dado que no aprenden representaciones que permiten utilizar métricas de similitud negativas (son *positive-definite*).

Observando que ambos enfoques logran buenos resultados de forma independiente pero presentan limitaciones complementarias, surge la motivación de combinar sus fortalezas en un solo marco híbrido. En este trabajo proponemos tres variantes que integran modelos lineales y *memory-based*: *Pipeline*, *Combine* y *Regularization*. A diferencia de trabajos anteriores, nuestro enfoque propone una integración explícita y sistemática entre estas dos clases de modelos, lo que no ha sido abordado en la literatura. Nuestro objetivo es evaluar si esta combinación permite superar las debilidades individuales y generar recomendaciones de mayor calidad.

2.Estado del Arte

Revisando implementaciones con el dataset *Amazon Book Reviews*, identificamos dos métodos que mostraban un rendimiento destacado y resultados competitivos frente a algoritmos *model-based*. Por el lado de los métodos lineales se encuentra *Data-Adaptive Normalization (DAN)*, mientras que entre los enfoques *memory-based* destaca *Sapling Similarity*.

DAN: corresponde a una técnica de normalización propues-

ta por (Park et al., 2025), que extiende los autoencoders lineales (LAE) mediante un escalamiento adaptativo basado en la actividad de usuarios y la popularidad de ítems. DAN introduce dos parámetros: α (para ítems) y β (para usuarios), los cuales permiten ajustar dinámicamente la influencia de ítems frecuentes y usuarios altamente activos. Esto se realiza a través de matrices de normalización que modifican la función objetivo y preservan la estructura de los datos. Con esto, DAN mitiga dos sesgos claves:

- **Sesgo de popularidad:** mediante la *item-adaptive normalization*, DAN penaliza la contribución de ítems populares en la reconstrucción, permitiendo una mayor exposición a ítems menos frecuentes.
- **Sesgo de vecinos cercanos:** la *user-adaptive normalization* reduce el sesgo hacia usuarios con alta conectividad, ajustando la estructura espectral del modelo para capturar relaciones globales y reducir redundancias locales.

Sapling Similarity: técnica introducida por (Albora et al., 2023) que redefine la noción de similaridad en sistemas de recomendación *memory-based*. A diferencia de métricas clásicas como Coseno o Jaccard, Sapling Similarity está basada en una perspectiva probabilística e interpretativa. El método modela la similaridad entre nodos (usuarios o ítems) mediante una estructura de tipo árbol (inspirada en árboles de decisión), en la que cada “rama” representa una partición basada en las conexiones locales de los nodos en la red bipartita usuario-ítem. El valor de similaridad se define como el impacto que tiene la conexión de un nodo con un ítem sobre la probabilidad de conexión de otro nodo con el mismo ítem, permitiendo valores tanto positivos como negativos. Esta capacidad para representar disimilitud (similaridad negativa) es crucial para capturar patrones de anti-correlación (como cuando usuarios con gustos opuestos tienden a evitar los mismos ítems), lo que a su vez mejora la diversidad y cobertura de las recomendaciones.

3. Metodología

En esta sección presentamos en detalle los tres enfoques propuestos para integrar las fortalezas de modelos lineales y métodos *memory-based* en sistemas de recomendación: *Pipeline*, *Combine* y *Regularization*. Estas variantes se basan en las salidas de los modelos DAN y Sapling Similarity, los cuales han demostrado ser efectivos por separado. El objetivo es explorar si su combinación puede superar las limitaciones individuales de cada método. A continuación, presentaremos cada uno de los tres enfoques propuestos, detallando su formulación y motivación.

- **Pipeline:** Este método implementa una integración secuencial de DAN y Sapling Similarity. En primer

lugar, se entrena un modelo DAN (como LAE-DAN, EASE-DAN o RLAE-DAN) utilizando la matriz de interacciones binaria $\mathbf{X} \in \{0, 1\}^{n \times m}$ como entrada, donde n es el número de usuarios y m el número de ítems. A partir de esto se genera una matriz de pesos $\mathbf{W} \in \mathbb{R}^{m \times m}$ que permite obtener la matriz de predicción inicial $\hat{\mathbf{X}} = \mathbf{X} \cdot \mathbf{W}$. Esta matriz densa $\hat{\mathbf{X}}$ es luego utilizada como entrada para el modelo Sapling Similarity, el cual calcula las matrices de similitud entre usuarios (\mathbf{S}_U) e ítems (\mathbf{S}_I) y genera una nueva matriz de recomendaciones como:

$$\mathbf{R} = (1 - \gamma) \cdot \mathbf{S}_U \cdot \hat{\mathbf{X}} + \gamma \cdot \hat{\mathbf{X}} \cdot \mathbf{S}_I$$

Este flujo permite refinar las recomendaciones densas aprendidas por DAN mediante la estructura local y relacional capturada por Sapling Similarity.

- **Combine:** A diferencia del método anterior, este enfoque ejecuta los modelos DAN y Sapling Similarity por separado, manteniendo sus respectivos flujos intactos. Primero, DAN produce una matriz de predicción $\mathbf{R}_{DAN} = \mathbf{X} \cdot \mathbf{W}$ como antes. Luego, Sapling Similarity se aplica directamente sobre la matriz binaria original \mathbf{X} , generando $\mathbf{R}_{Sapling} = (1 - \gamma) \cdot \mathbf{S}_U \cdot \mathbf{X} + \gamma \cdot \mathbf{X} \cdot \mathbf{S}_I$. Finalmente, se realiza una combinación lineal ponderada entre ambas matrices de predicción mediante un hiperparámetro $\alpha \in [0, 1]$:

$$\mathbf{R} = (1 - \alpha) \cdot \mathbf{R}_{DAN} + \alpha \cdot \mathbf{R}_{Sapling}$$

Este modelo busca capturar tanto las relaciones implícitas aprendidas por DAN como la estructura explícita de similitud y disimilitud modelada por Sapling.

- **Regularization:** Este método propone una integración más profunda entre ambos enfoques al modificar directamente la función de optimización de DAN. Primero, se computa la matriz de similitud entre ítems $\mathbf{S}_{Sapling}$ usando la formulación original de Sapling Similarity con proyección sobre ítems. Luego, esta matriz se incorpora como un término de penalización en la matriz de coocurrencia \mathbf{G} del modelo DAN:

$$\mathbf{G} \leftarrow \mathbf{G} + \eta \cdot (\mathbf{I} - \mathbf{S}_{Sapling})$$

donde η es un hiperparámetro de regularización. Este término penaliza fuertemente las relaciones entre ítems que Sapling considera disímiles, forzando a DAN a ajustar su matriz de pesos \mathbf{W} respetando la estructura de disimilitud informada por Sapling. La salida final del modelo es, como antes, $\mathbf{R} = \mathbf{X} \cdot \mathbf{W}$. A diferencia de los enfoques anteriores, esta estrategia busca guiar el aprendizaje de DAN incorporando conocimiento relacional de forma explícita en su optimización, lo que puede inducir mayor diversidad en las recomendaciones.

Este modelo es simple y flexible, y permite ajustar el peso relativo que se le otorga a las recomendaciones generadas por cada enfoque. La motivación detrás de esta combinación es capturar simultáneamente patrones globales (DAN) y locales (Sapling), con el objetivo de mejorar tanto la precisión como la cobertura de las recomendaciones.

4. Experimentación

4.1. Montaje Experimental y Datasets

Dataset	#Usuarios	#Items	#Interacciones
Amazon Books	10,3M	4,4M	29,5M
Amazon Product	186K	90K	204K
Yelp Reviews	1,9M	150K	6,9M
MovieLens	43K	15K	891K

Tabla 1. Detalle de los datasets utilizados

En este estudio se comparan cinco enfoques de recomendación: *DAN*, *Sapling Similarity*, *Pipeline*, *Combine* y *Regularization*. Estos modelos se construyen sobre distintos métodos lineales, específicamente *LAE* (Linear Autoencoder), *EASE* y *RLAE*, aplicando normalización adaptativa (DAN), regularización o combinaciones secuenciales. La idea central es explorar cómo la incorporación de métodos *memory-based* como *Sapling Similarity* puede integrarse o mejorar métodos basados en autoencoders lineales.

Para hacer esta comparación de enfoques, utilizamos cuatro conjuntos de datos reales ampliamente utilizados en sistemas de recomendación: *Amazon Reviews Books*, *Amazon Product Review*, *Yelp Reviews* y *MovieLens*. Estos datasets nos permiten evaluar el rendimiento de nuestro enfoque en distintos contextos, desde reseñas textuales hasta calificaciones numéricas, cubriendo dominios como libros, productos de consumo, servicios locales y películas.

Amazon Reviews Books: conjunto de datos que proviene de la colección de reseñas de productos de Amazon (Hou et al., 2024). Contiene opiniones de clientes específicamente sobre libros, en formato sin procesar. Cada entrada incluye campos como el identificador del producto, la reseña textual, la puntuación otorgada (de 1 a 5 estrellas), y metadatos adicionales como fecha y usuario.

Amazon Product Review: contiene reseñas de productos de Amazon, abarcando múltiples categorías (Thành, 2024). Incluye información detallada del producto, comentarios de usuarios, puntuaciones y otros atributos.

Yelp Reviews: Este conjunto de datos proviene del proyecto abierto de Yelp y contiene reseñas de usuarios sobre distintos negocios, principalmente restaurantes y servicios locales (Raizada, 2024). Cada entrada incluye texto de la reseña, puntuación, fecha, identificadores del negocio y del usuario.

MovieLens: MovieLens es un dataset clásico para sistemas de recomendación, compuesto por calificaciones (de 1 a 5 estrellas) realizadas sobre películas (Ashraq, 2022). Proporciona metadatos como género, título y año de las películas.

4.2. Resultados

Para cada uno de estos datasets se seleccionaron 15.000 reseñas de manera aleatoria y se entrenaron los cinco modelos descritos anteriormente. Los resultados obtenidos se presentan en la Tabla 2.

Los resultados presentados muestran de manera clara que la integración entre métodos lineales y enfoques *memory-based* puede ser beneficiosa para los sistemas de recomendación, especialmente cuando se busca un balance entre precisión y diversidad. En particular, el enfoque de *Regularization* se destaca como el modelo con mejor rendimiento en el dataset de *Yelp Reviews*, superando tanto a *Sapling Similarity* como a los modelos lineales básicos (DAN) en todas las métricas principales (Precision, Recall, nDCG), sin comprometer la diversidad. Esto sugiere que incorporar conocimiento relacional explícito dentro de la función de optimización de los modelos lineales permite capturar patrones más globales y menos redundantes, alineándose con el objetivo de mitigar los sesgos estructurales como la popularidad o la cercanía en la red de usuarios e ítems.

Por otro lado, los resultados en el dataset de *Amazon Products* revelan un comportamiento interesante: aunque *Sapling Similarity* logra métricas de precisión notablemente más altas que el resto de los modelos, su integración mediante los métodos híbridos (*Pipeline*, *Combine* y *Regularization*) no logra mantener ese nivel de rendimiento. Esto podría deberse a una pérdida de señal durante el proceso de combinación o a una subóptima sintonización de los hiperparámetros en estos escenarios. Sin embargo, estos métodos híbridos muestran consistentemente valores elevados de diversidad, lo que indica que, aunque se sacrifica algo de precisión, se gana en variedad de recomendaciones. En conjunto, los resultados refuerzan la hipótesis de que combinar enfoques lineales y *memory-based* permite abordar simultáneamente distintas dimensiones de calidad en la recomendación, aunque se requiere una calibración cuidadosa para maximizar sus beneficios.

4.3. Análisis de Parámetros

Luego se realizó un análisis de sensibilidad para el método *Combine* variando en primer lugar el parámetro α que corresponde a cual de los modelos se le daba más peso en la recomendación final del usuario, y se ocupó como autoencoder *LAE* para todas estas pruebas. A continuación, se variaron los parámetros internos propios de DAN, específicamente reg_p , β , $drop_p$, x_i , y ϵ . Los resultados se

encuentran disponibles en la Tabla 3.

Los resultados del análisis de sensibilidad sobre el método *Combine* revelan comportamientos interesantes respecto a la influencia del parámetro α , el cual regula el peso relativo entre los modelos DAN y Sapling Similarity. Se observa que valores bajos de α (por ejemplo, 0.0–0.1), donde se da mayor peso a DAN, generan los valores más altos de precisión y recall (0.000668 y 0.005448 respectivamente), a costa de una reducción en diversidad. A medida que α aumenta, es decir, se otorga mayor peso a Sapling, la diversidad se estabiliza en torno a 0.474 y la novedad se incrementa de forma consistente. Sin embargo, la precisión sufre una caída progresiva, destacando que una mayor influencia de Sapling en la combinación mejora la diversidad y novedad pero sacrifica calidad de predicción. Esto refuerza la idea de que el parámetro α actúa como un control de compromiso entre precisión y diversidad.

Por otro lado, al variar los hiperparámetros internos de DAN, como reg_p , β , $drop_p$, ξ y η , los resultados muestran que el sistema es en gran parte insensible a dichos cambios en la mayoría de las métricas. Por ejemplo, las variaciones en ξ y η no alteran ninguna métrica de forma perceptible, lo cual sugiere que estos parámetros pueden tener un efecto secundario en el contexto del método combinado. En contraste, $drop_p$ y reg_p presentan ligeras mejoras en recall y ndcg cuando se ajustan, particularmente para valores más bajos. Estos hallazgos sugieren que mientras el ajuste fino de α es crucial para controlar el equilibrio entre precisión y diversidad, la robustez del modelo ante otros hiperparámetros aporta flexibilidad operativa sin necesidad de una sintonización extensa.

5. Conclusiones

Los resultados obtenidos en este trabajo evidencian que la integración sistemática de modelos lineales y métodos *memory-based* constituye una estrategia efectiva para mejorar los sistemas de recomendación. Al combinar la capacidad de generalización y eficiencia de modelos como DAN con la riqueza estructural y la capacidad de representar disimilitudes de Sapling Similarity, se logran modelos híbridos que no solo mantienen un rendimiento competitivo en precisión, sino que también amplían considerablemente la diversidad y cobertura de las recomendaciones. En particular, el enfoque de Regularization demostró ser el más robusto al incorporar información relacional directamente en la función de optimización, superando a los métodos individuales en varios escenarios y datasets.

Asimismo, el análisis de sensibilidad realizado sobre el modelo *Combine* permitió identificar cómo el hiperparámetro α actúa como un mecanismo de control entre precisión y diversidad, revelando que una combinación equilibrada

entre DAN y Sapling puede ofrecer resultados más consistentes. Además, la estabilidad del sistema frente a cambios en hiperparámetros internos de DAN como ξ y η refleja la robustez del enfoque propuesto, lo que representa una ventaja práctica en contextos reales donde la sintonización extensa de parámetros puede ser costosa. En conjunto, este estudio no solo confirma que la combinación de enfoques complementarios es viable, sino que abre el camino a nuevas exploraciones híbridas orientadas a mitigar los sesgos estructurales tradicionales sin comprometer la calidad ni la diversidad de las recomendaciones.

Referencias

- Albora, G., Mori, L. R., and Zaccaria, A. Sapling similarity: A performing and interpretable memory-based tool for recommendation. *arXiv preprint arXiv:2210.07039*, 2023. URL <https://arxiv.org/abs/2210.07039>.
- Ashraq, I. Movielens ratings dataset. https://huggingface.co/datasets/ashraq/movielens_ratings, 2022. Accedido: 2025-07-06.
- Hou, Y., Li, J., He, Z., Yan, A., Chen, X., and McAuley, J. Bridging language and items for retrieval and recommendation. *arXiv preprint arXiv:2403.03952*, 2024.
- Park, S., Yoon, M., young Kim, H., and Lee, J. Why is normalization necessary for linear recommenders? In *Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '25)*. ACM, 2025. doi: 10.1145/3726302.3730116.
- Raizada, Y. Yelp open dataset reviews. <https://huggingface.co/datasets/yashraizada/yelp-open-dataset-reviews>, 2024. Accedido: 2025-07-06.
- Thành, N. M. Amazon product review 283k. https://huggingface.co/datasets/minhth2nh/amazon_product_review_283K, 2024. Accedido: 2025-07-06.

A. Apéndice

A.1. Tablas de resultados

Dataset	Model	Normalization	Precision	Recall	nDCG	Diversity
Yelp Reviews	Regularization	LAE	0.0045	0.0899	0.0378	0.9999
Yelp Reviews	Regularization	EASE	0.0045	0.0899	0.0379	0.9999
Yelp Reviews	Regularization	RLAE	0.0045	0.0899	0.0378	0.9999
Yelp Reviews	Sapling	-	0.0033	0.0654	0.0225	0.9999
Amazon Products	Regularization	EASE	0.0003	0.0034	0.0010	0.8660
Amazon Products	Regularization	RLAE	0.0003	0.0034	0.0011	0.8692
Amazon Products	Pipeline	RLAE	0.0001	0.0013	0.0003	0.9963
Amazon Products	Pipeline	LAE	0.0001	0.0013	0.0003	0.9963
Amazon Products	Pipeline	EASE	0.0001	0.0013	0.0003	0.9963
Amazon Products	Combine	EASE	0.0001	0.0007	0.0003	0.9462
Amazon Products	Combine	RLAE	0.0001	0.0007	0.0003	0.9462
Amazon Products	Combine	LAE	0.0001	0.0007	0.0003	0.9462
Amazon Products	Dan	RLAE	0.0002	0.0008	0.0003	0.9689
Amazon Products	Dan	LAE	0.0002	0.0008	0.0003	0.9689
Amazon Products	Dan	EASE	0.0001	0.0004	0.0002	0.9690
Amazon Products	Sapling	-	0.0015	0.0287	0.0104	0.9716
Amazon Books	Pipeline	RLAE	0.0005	0.0021	0.0008	0.9433
Amazon Books	Pipeline	LAE	0.0005	0.0021	0.0008	0.9433
Amazon Books	Pipeline	EASE	0.0005	0.0021	0.0008	0.9433
Amazon Books	Dan	LAE	0.0010	0.0003	0.0010	0.7435

Tabla 2. Top 20 resultados en k@20 basados en precisión

varied_param	varied_value	precision	recall	ndcg	diversity	novelty
alpha	0.0	0.000602	0.005448	0.002019	0.823534	12.601032
alpha	0.1	0.000668	0.004132	0.001731	0.476683	12.453639
alpha	0.2	0.000535	0.002782	0.001305	0.475071	12.456577
alpha	0.3	0.000602	0.002793	0.001386	0.474667	12.457648
alpha	0.4	0.000401	0.002777	0.001567	0.474747	12.458580
alpha	0.5	0.000401	0.004102	0.001431	0.474571	12.459211
alpha	0.6	0.000334	0.004085	0.001381	0.474738	12.459550
alpha	0.7	0.000401	0.004102	0.001475	0.474184	12.459981
alpha	0.8	0.000334	0.004085	0.001450	0.473854	12.460243
alpha	0.9	0.000401	0.004102	0.001600	0.473510	12.460311
alpha	1.0	0.000267	0.002748	0.001002	0.472139	12.460451
reg_p	5.0	0.000334	0.002750	0.001975	0.475867	12.457093
reg_p	10.0	0.000401	0.002753	0.001109	0.475694	12.456886
reg_p	20.0	0.000535	0.002782	0.001305	0.475071	12.456577
beta	0.1	0.000468	0.002771	0.001570	0.475092	12.457247
beta	0.3	0.000535	0.002782	0.001305	0.475071	12.456577
beta	0.5	0.000535	0.002782	0.001288	0.475364	12.456216
drop_p	0.3	0.000535	0.004108	0.001942	0.474860	12.456695
drop_p	0.5	0.000535	0.002782	0.001305	0.475071	12.456577
drop_p	0.7	0.000602	0.004114	0.001810	0.475092	12.456421
xi	0.1	0.000535	0.002782	0.001305	0.475071	12.456577
xi	0.3	0.000535	0.002782	0.001305	0.475071	12.456577
xi	0.5	0.000535	0.002782	0.001305	0.475071	12.456577
eta	5.0	0.000535	0.002782	0.001305	0.475071	12.456577
eta	10.0	0.000535	0.002782	0.001305	0.475071	12.456577
eta	20.0	0.000535	0.002782	0.001305	0.475071	12.456577

Tabla 3. Análisis de sensibilidad en k@20

A.2.Simulación de Recomendaciones: Combine + EASE

Modelo: Combine + EASE

Segundo mejor modelo en rendimiento NDCG@20

Dataset: amazon_reviews_books

Usuarios: 434 **Ítems:** 4585

Recomendaciones generadas para el Usuario 0:

- **Perfil de usuario:** God Gave Us You (ASIN: 1578563232)
- **Últimas reseñas:**
 - "Great gift and value!!" (Puntaje: 5.0/5)
 - ".^ FAVORITE book" (Puntaje: 5.0/5)
 - "Beautiful Illustrations" (Puntaje: 5.0/5)

Top 5 recomendaciones generadas:

1. **The Red Sea Rules: 10 God-Given Strategies for Difficult Times**
 ASIN: 0529104407 **Puntaje:** 0.0830
Descripción: About the Author
2. **Blood Money (Paperback) - Common**
 ASIN: B00IVM320A **Puntaje:** 0.0830
Descripción: No description available
3. **Blood Money**
 ASIN: 1936724413 **Puntaje:** 0.0830
Descripción: No description available
4. **Forgiving What You Can't Forget: Discover How to Move On, Make Peace with Painful Memories, and Create a Life That's Beautiful Again**
 ASIN: 0718039874 **Puntaje:** 0.0830
Descripción: About the Author
5. **First 100 Words: A Padded Board Book**
 ASIN: 0312510780 **Puntaje:** -0.0000
Descripción: Review

Detalles del modelo:

- **Modelo:** Combine
- **Normalización:** EASE
- **Parámetros:**
 - α (peso de combinación): 0.5
 - γ (parámetro Sapling): 0.5
- **Configuración interna:** {reg_p: 20, alpha: 0.2, beta: 0.3, drop_p: 0.5, xi: 0.3, eta: 10}